


# 机器视觉技术 拟合

Fitting — 中文翻译版（含原图）

共 40 页 | 翻译时间：2026年6月

# Fitting

(Least squares & RANSAC)



## 最小二乘法与RANSAC

本章节主要介绍曲线拟合中的两种核心方法：最小二乘法（用于无离群点情况）和RANSAC随机采样一致性算法（用于存在大量离群点的情况）。

左侧图为金属焊盘的再分布凸点图像，展示了需要拟合的几何特征。

| Machine Vision Technology                                    |                            |                          |                    |                       |                       |                      |     |
|--------------------------------------------------------------|----------------------------|--------------------------|--------------------|-----------------------|-----------------------|----------------------|-----|
| Semantic information                                         |                            |                          |                    | Metric 3D information |                       |                      |     |
| Pixels                                                       | Segments                   | Images                   | Videos             | Camera                |                       | Multi-view Geometry  |     |
| Convolutions<br>Edges & Fitting<br>Local features<br>Texture | Segmentation<br>Clustering | Recognition<br>Detection | Motion<br>Tracking | Camera<br>Model       | Camera<br>Calibration | Epipolar<br>Geometry | SFM |
| 10                                                           | 4                          | 4                        | 2                  | 2                     | 2                     | 2                    | 2   |

## 机器视觉技术

语义信息 ← → 度量三维信息

像素 → 分割 → 图像 → 视频 → 相机 → 多视图几何

### 拟合

课程体系概览：从底层像素处理到高层语义理解，拟合是连接特征提取与三维重建的关键环节。

## Fitting

- We've learned how to detect edges. Now what?
- We would like to form a higher-level, more compact representation of the features in the image by grouping multiple features according to a simple model



Source: S. Lazebnik

2

## 拟合

- 我们已经学习了如何检测边缘、角点等特征
- 现在我们希望形成更高级、更紧凑的特征表示
- 通过根据一个简单模型将多个特征分组

简单模型示例：

——直线

——圆


来源：S. Lazebnik



## Fitting

---


- Choose a parametric model to represent a set of features



simple model: lines



simple model: circles



complicated model: car

Source: K. Grauman

3

---

## 拟合

- 选择一个参数化模型来表示一组特征

简单模型：直线 简单模型：圆

复杂模型：汽车轮廓

来源：K. Grauman

---

## Fitting: Issues

---

### Case study: Line detection



- **Noise** in the measured feature locations
- **Extraneous data**: clutter (outliers), multiple lines
- **Missing data**: occlusions

Source: S. Lazebnik

4

---

## 拟合：面临的挑战

### 案例研究：直线检测

- 测量特征位置中的噪声
- 冗余数据：杂乱背景（离群点）、多条直线
- 缺失数据：遮挡问题

来源：S. Lazebnik

---

## Fitting: Overview

---

- If we know which points belong to the line, how do we find the “optimal” line parameters?
  - Least squares
- What if there are outliers?
  - Robust fitting, RANSAC
- What if there are many lines?
  - Voting methods: RANSAC, Hough transform
- What if we’re not even sure it’s a line?
  - Model selection

Source: S. Lazebnik

5

---

## 拟合：概述

- 如果我们知道哪些点属于这条直线，如何找到「最优」的直线参数？  
→ 最小二乘法
- 如果存在离群点怎么办？  
→ 鲁棒拟合，RANSAC
- 如果有很多条直线怎么办？  
→ 投票方法：RANSAC，霍夫变换
- 如果我们甚至不确定它是不是直线？  
→ 模型选择

来源：S. Lazebnik

---


# Least squares line fitting

Data:  $(x_1, y_1), \dots, (x_n, y_n)$

Line equation:  $y_i = mx_i + b$

Find  $(m, b)$  to minimize

$$E = \sum_{i=1}^n (y_i - mx_i - b)^2$$



$$Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \quad X = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \quad B = \begin{bmatrix} m \\ b \end{bmatrix}$$

$$E = \|Y - XB\|^2 = (Y - XB)^T (Y - XB) = Y^T Y - 2(XB)^T Y + (XB)^T (XB)$$

$$\frac{dE}{dB} = 2X^T XB - 2X^T Y = 0$$

$$\boxed{X^T XB = X^T Y} \quad \text{Normal equations: least squares solution to } XB=Y$$

Source: S. Lazebnik

6

## 最小二乘直线拟合

数据:  $(x_1, y_1), \dots, (x_n, y_n)$

直线方程:  $y_i = mx_i + b$

求  $(m, b)$  使以下目标函数最小化:

$$E = \sum (y_i - mx_i - b)^2$$

用矩阵形式表示:

$$E = \|Y - XB\|^2 = (Y - XB)^T (Y - XB) \\ = Y^T Y - 2(XB)^T Y + (XB)^T (XB)$$

$$dE/dB = 2X^T XB - 2X^T Y = 0$$

$$\text{正规方程: } X^T XB = X^T Y$$

来源: S. Lazebnik

学习补充:

- 直线模型里, 斜率决定倾斜程度, 截距决定与 y 轴的交点。
- 最小二乘要做的是让所有点到直线的误差平方和最小, 因此会得到正规方程。

## Problem with “vertical” least squares

---

- Not rotation-invariant
- Fails completely for vertical lines

Source: S. Lazebnik

7

---

### 「垂直」最小二乘法的问题

- 不具备旋转不变性
- 对于垂直直线完全失效


标准最小二乘法最小化的是  $y$  方向的垂直距离，当直线接近垂直时，误差计算会严重失真。

来源：S. Lazebnik

学习补充：

- 直线模型里，斜率决定倾斜程度，截距决定与  $y$  轴的交点。
  - 最小二乘要做的是让所有点到直线的误差平方和最小，因此会得到正规方程。
-

## Total least squares



Source: S. Lazebnik

8

### 总体最小二乘法

点  $(x_i, y_i)$  到直线  $ax + by = d$  的距离 (其中  $a^2 + b^2 = 1$ ) :

$$\text{距离} = |ax_i + by_i - d|$$

直线:  $ax + by = d$

单位法向量:  $N = (a, b)$

总体最小二乘法最小化的是点到直线的垂直 (正交) 距离, 而非仅仅是  $y$  方向的偏差。

来源: S. Lazebnik

学习补充:


- 当  $x/y$  两个方向都存在测量误差时, 单纯看竖直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。

## Total least squares

Distance between point  $(x_i, y_i)$  and line  $ax+by=d$  ( $a^2+b^2=1$ )  
 $|ax_i + by_i - d|$

Find  $(a, b, d)$  to minimize the sum of squared perpendicular distances

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$



Source: S. Lazebnik

9

### 总体最小二乘法

点  $(x_i, y_i)$  到直线  $ax + by = d$  的距离 (其中  $a^2 + b^2 = 1$ ) :

$$|ax_i + by_i - d|$$

求  $(a, b, d)$  使垂直距离的平方和最小化:

单位法向量:  $N = (a, b)$

$$E = \sum (ax_i + by_i - d)^2$$

来源: S. Lazebnik

学习补充:

- 当  $x/y$  两个方向都存在测量误差时, 单纯看竖直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。


# Total least squares

Distance between point  $(x_i, y_i)$  and line  $ax+by=d$  ( $a^2+b^2=1$ )

$$|ax_i + by_i - d|$$

Find  $(a, b, d)$  to minimize the sum of squared perpendicular distances

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$



$$\frac{\partial E}{\partial d} = \sum_{i=1}^n -2(ax_i + by_i - d) = 0$$

$$d = \frac{a}{n} \sum_{i=1}^n x_i + \frac{b}{n} \sum_{i=1}^n y_i = a\bar{x} + b\bar{y}$$

$$E = \sum_{i=1}^n (a(x_i - \bar{x}) + b(y_i - \bar{y}))^2 = \left\| \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \right\|^2 = (UN)^T (UN)$$

$$\frac{dE}{dN} = 2(U^T U)N = 0$$

Solution to  $(U^T U)N = 0$ , subject to  $\|N\|^2 = 1$ : eigenvector of  $U^T U$  associated with the smallest eigenvalue (least squares solution to *homogeneous linear system*  $UN = 0$ )

Source: S. Lazebnik

10

## 总体最小二乘法（推导）

点  $(x_i, y_i)$  到直线  $ax + by = d$  的距离 ( $a^2 + b^2 = 1$ ):

$$|ax_i + by_i - d|$$

求  $(a, b, d)$  使垂直距离平方和最小化: 单位法向量  $N = (a, b)$

$$E = \sum (ax_i + by_i - d)^2$$

$$\partial E / \partial d = \sum 2(ax_i + by_i - d) = 0$$

$$\Rightarrow d = (a/n) \sum x_i + (b/n) \sum y_i = a\bar{x} + b\bar{y}$$

将数据中心化后:

$$U = [x_1 - \bar{x}, y_1 - \bar{y}; \dots; x_n - \bar{x}, y_n - \bar{y}]$$

$$E = \sum (a(x_i - \bar{x}) + b(y_i - \bar{y}))^2 = \|UN\|^2 = (UN)^T (UN)$$

$$dE/dN = 2(U^T U)N = 0$$

解: 在  $\|N\|^2 = 1$  约束下, 求  $(U^T U)N = 0$  的解, 即  $U^T U$  最小特征值对应的特征向量  
(齐次线性系统  $UN = 0$  的最小二乘解)

来源: S. Lazebnik

学习补充:

- 当  $x/y$  两个方向都存在测量误差时, 单纯看垂直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。



## Total least squares

$$U = \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \quad U^T U = \begin{bmatrix} \sum_{i=1}^n (x_i - \bar{x})^2 & \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) & \sum_{i=1}^n (y_i - \bar{y})^2 \end{bmatrix}$$

second moment matrix

Source: S. Lazebnik

11

### 总体最小二乘法（二阶矩矩阵）

数据中心化矩阵：

$$U = [x_1 - \bar{x}, y_1 - \bar{y}; x_2 - \bar{x}, y_2 - \bar{y}; \dots; x_n - \bar{x}, y_n - \bar{y}]$$

$$U^T U = [\Sigma(x_i - \bar{x})^2, \Sigma(x_i - \bar{x})(y_i - \bar{y}); \Sigma(x_i - \bar{x})(y_i - \bar{y}), \Sigma(y_i - \bar{y})^2]$$

这就是数据点的 二阶矩矩阵（散布矩阵）


来源：S. Lazebnik

学习补充：

- 当  $x/y$  两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

## Total least squares

$$U = \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \quad U^T U = \begin{bmatrix} \sum_{i=1}^n (x_i - \bar{x})^2 & \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) & \sum_{i=1}^n (y_i - \bar{y})^2 \end{bmatrix}$$



Source: S. Lazebnik

12

### 总体最小二乘法（几何解释）

数据点的二阶矩矩阵  $U^T U$ :

$$U^T U = [\Sigma(x_i - \bar{x})^2, \Sigma(x_i - \bar{x})(y_i - \bar{y}); \Sigma(x_i - \bar{x})(y_i - \bar{y}), \Sigma(y_i - \bar{y})^2]$$

法向量  $N = (a, b)$  对应  $U^T U$  的最小特征值所对应的特征向量

几何上，总体最小二乘法寻找使数据点沿法线方向方差最小的直线方向。

图示说明了点  $(\bar{x}, \bar{y})$  与拟合直线之间的关系。

来源: S. Lazebnik

学习补充:


- 当  $x/y$  两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

## Least squares as likelihood maximization

- **Generative model:** line points are sampled independently and corrupted by Gaussian noise in the direction perpendicular to the line

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} u \\ v \end{pmatrix} + \varepsilon \begin{pmatrix} a \\ b \end{pmatrix}$$

point on the line      noise: sampled from zero-mean Gaussian with std. dev.  $\sigma$       normal direction



Source: S. Lazebnik

13

### 最小二乘法作为似然最大化

- 生成模型：直线上的点被独立采样，并在垂直于直线的方向上被高斯噪声干扰

$$(x, y) = (u, v) + \varepsilon \cdot (a, b)$$

其中：

$(u, v)$  — 直线上的一点

$(a, b)$  — 法线方向

$\varepsilon$  — 从均值为零、标准差为 $\sigma$ 的高斯分布中采样的噪声

来源：S. Lazebnik


学习补充：

- 当 $x/y$ 两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

## Least squares as likelihood maximization

- **Generative model:** line points are sampled independently and corrupted by Gaussian noise in the direction perpendicular to the line

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} u \\ v \end{pmatrix} + \varepsilon \begin{pmatrix} a \\ b \end{pmatrix}$$



*Likelihood* of points given line parameters  $(a, b, d)$ :

$$P(x_1, y_1, \dots, x_n, y_n | a, b, d) = \prod_{i=1}^n P(x_i, y_i | a, b, d) \propto \prod_{i=1}^n \exp\left(-\frac{(ax_i + by_i - d)^2}{2\sigma^2}\right)$$

$$\text{Log-likelihood: } L(x_1, y_1, \dots, x_n, y_n | a, b, d) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (ax_i + by_i - d)^2$$

Source: S. Lazebnik

14

### 最小二乘法作为似然最大化（续）

- 生成模型：直线上的点被独立采样，在法线方向上被高斯噪声干扰

$$(x, y) = (u, v) + \varepsilon \cdot (a, b)$$

给定直线参数  $(a, b, d)$ ，数据点的似然函数：

$$P(x_1, y_1, \dots, x_n, y_n | a, b, d) = \prod_i P(x_i, y_i | a, b, d) \propto \prod_i \exp(-(ax_i + by_i - d)^2 / (2\sigma^2))$$

对数似然：

$$L(x_1, y_1, \dots, x_n, y_n | a, b, d) = -(1/(2\sigma^2)) \cdot \sum (ax_i + by_i - d)^2$$

最大化对数似然等价于最小化残差平方和，即最小二乘法的概率解释。

来源：S. Lazebnik


学习补充：

- 当  $x/y$  两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

## Least squares: Robustness to noise

---

Least squares fit to the red points:



Source: S.  
Lazebnik

15

---

### 最小二乘法：对噪声的鲁棒性

对红色点集进行最小二乘拟合：

如图所示，当数据点分布良好（无离群点）时，最小二乘拟合效果很好，能准确地找到最佳拟合直线。


来源：S. Lazebnik

---

## Least squares: Robustness to noise

---

Least squares fit with an outlier:



Problem: squared error  
heavily penalizes outliers

Source: S. Lazebnik

16

---

### 最小二乘法：对噪声的鲁棒性

存在一个离群点时的最小二乘拟合：

问题：平方误差对离群点施加了极大的惩罚

如图所示，仅一个离群点就严重扭曲了拟合结果，因为最小二乘法中误差的平方会放大离群点的影响。

来源：S. Lazebnik

---


## Robust estimators

- General approach: find model parameters  $\theta$  that minimize

$$\sum_i \rho(r_i(x_i, \theta); \sigma)$$

$r_i(x_i, \theta)$  – residual of  $i$ th point w.r.t. model parameters  $\theta$

$\rho$  – robust function with scale parameter  $\sigma$



The robust function  $\rho$  behaves like squared distance for small values of the residual  $u$  but saturates for larger values of  $u$

Source: S. Lazebnik

17

### 鲁棒估计器

- 一般方法：寻找模型参数  $\theta$  使得：

$$\sum_i \rho(r_i(x_i, \theta); \sigma)$$

其中：

$r_i(x_i, \theta)$  — 第  $i$  个点相对于模型参数  $\theta$  的残差

$\rho$  — 具有尺度参数  $\sigma$  的鲁棒函数

- 鲁棒函数  $\rho$  的行为：  
对于较小的残差值，表现类似于平方距离  
对于较大的残差值，函数值趋于饱和（不再增长）


来源：S. Lazebnik

学习补充：

- 鲁棒估计的目的，是让少数离群点不要把整体模型带偏。
- 和普通最小二乘相比，它会弱化大残差点的影响，因此对异常值更稳。

## Choosing the scale: Just right

---



The effect of the outlier is minimized

Source: S. Lazebnik

18

---

### 尺度参数的选择：恰到好处

如图所示，当尺度参数选择恰当时：

离群点的影响被最小化

鲁棒函数有效地抑制了离群点对拟合结果的贡献，同时保留了对内点的良好拟合效果。


来源：S. Lazebnik

---



## Choosing the scale: Too small

---



The error value is almost the same for every point and the fit is very poor

Source: S. Lazebnik

19

---

### 尺度参数的选择：过小

如图所示，当尺度参数过小时：

每个点的误差值几乎相同，拟合结果非常差


尺度参数过小会导致鲁棒函数对所有点（包括内点）都饱和，无法区分好点和坏点，拟合失去意义。

来源：S. Lazebnik

---

## Choosing the scale: Too large

---



Behaves much the same as least squares

Source: S. Lazebnik

20

---

### 尺度参数的选择：过大

如图所示，当尺度参数过大时：

行为与最小二乘法几乎相同

尺度参数过大使鲁棒函数的饱和区域过远，大部分点（包括离群点）都落在二次函数区域内，失去了鲁棒性。

来源：S. Lazebnik

---

## Robust estimation: Details

- Robust fitting is a nonlinear optimization problem that must be solved iteratively
- Least squares solution can be used for initialization
- Adaptive choice of scale: approx. 1.5 times median residual (F&P, Sec. 15.5.1)

```

For  $s$  从 1 到  $k$ , 执行循环:
    均匀随机抽取  $r$  个不同的点
    采用最小二乘法拟合该点集得到初始参数  $\theta_s^0$ 
    用  $\theta_s^0$  估计出  $\sigma_s^0$ 
    Until 收敛 (一般指  $|\theta_s^n - \theta_s^{n-1}|$  足够小), 执行以下操作:
        用  $\theta_s^{n-1}, \sigma_s^{n-1}$  通过最小化方法求得  $\theta_s^n$ 
        计算出  $\sigma_s^n$ 
    End
End
  
```

Source: S. Lazebnik

21

## 鲁棒估计：细节

- 鲁棒拟合是一个非线性优化问题，必须通过迭代求解
- 最小二乘解可用于初始化
- 尺度的自适应选择：约为残差中位数的 1.5 倍 (F&P, 第 15.5.1 节)

算法伪代码：

1. 使用所有点获取初始拟合（如最小二乘）
2. 计算残差并确定尺度参数  $\sigma$
3. 使用鲁棒权重进行加权最小二乘拟合
4. 重复步骤 2-3 直到收敛

来源：S. Lazebnik

## RANSAC

---

- Robust fitting can deal with a few outliers – what if we have very many?
- Random sample consensus (RANSAC):  
Very general framework for model fitting in the presence of outliers
- Outline
  - Choose a small subset of points uniformly at random
  - Fit a model to that subset
  - Find all remaining points that are “close” to the model and reject the rest as outliers
  - Do this many times and choose the best model

M. A. Fischler, R. C. Bolles. [Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography](#). Comm. of the ACM, Vol 24, pp 381-395, 1981.

Source: S. Lazebnik

22

---

### RANSAC（随机采样一致性）

• 鲁棒拟合可以处理少量离群点 —— 但如果离群点非常多呢？

• 随机采样一致性（RANSAC）：  
在存在离群点的情况下进行模型拟合的通用框架

- 算法概要：
- 随机均匀地选择一个小的点子集
- 对该子集拟合一个模型
- 找出所有「接近」模型的剩余点，将其他点作为离群点剔除
- 重复多次，选择最佳模型

文献：M.A. Fischler, R.C. Bolles. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. Comm. of the ACM, Vol 24, pp 381-395, 1981.

来源：S. Lazebnik

学习补充：

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
  - $s$  是最小样本数， $d$  是内点阈值， $N$  是重复次数；这些参数共同控制鲁棒性和计算量。
-

## RANSAC for line fitting example

---



Source: R. Raguram

23

---

### RANSAC直线拟合示例


以下幻灯片展示了RANSAC算法对直线拟合的逐步演示过程。

图中包含一组数据点，其中既有直线上的内点，也有随机分布的离群点。

---

## RANSAC for line fitting example

---



Least-squares fit

Source: R. Raguram

24

---

### RANSAC直线拟合示例

首先展示最小二乘拟合的结果：


由于存在大量离群点，最小二乘拟合被严重偏离，无法找到正确的直线。

来源：R. Raguram

---

## RANSAC for line fitting example

---



1. Randomly select minimal subset of points

Source: R. Raguram

25

---

## RANSAC直线拟合示例

### 步骤 1：随机选择最小子集


从所有点中随机均匀地选取两个点（拟合直线所需的最少点数）。

来源：R. Raguram

---

## RANSAC for line fitting example

---



1. Randomly select minimal subset of points
2. Hypothesize a model

Source: R. Raguram

26

---

### RANSAC直线拟合示例

步骤 1：随机选择最小子集

步骤 2：假设一个模型

使用选中的两个点拟合一条直线作为假设模型。


来源：R. Raguram

---



## RANSAC for line fitting example

---



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function

Source: R. Raguram

27

---

### RANSAC直线拟合示例

步骤 1：随机选择最小子集

步骤 2：假设一个模型

步骤 3：计算误差函数


计算所有其他点到该假设直线的距离。

来源：R. Raguram

---

## RANSAC for line fitting example

---



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model

Source: R. Raguram

28

---

### RANSAC直线拟合示例

- 步骤 1：随机选择最小子集
- 步骤 2：假设一个模型
- 步骤 3：计算误差函数
- 步骤 4：选择与模型一致的点


将与直线距离小于阈值  $t$  的点标记为内点 (inliers)。

来源：R. Raguram

---

## RANSAC for line fitting example

---



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat *hypothesize-and-verify* loop

Source: R. Raguram

29

---

### RANSAC直线拟合示例


- 步骤 1：随机选择最小子集
- 步骤 2：假设一个模型
- 步骤 3：计算误差函数
- 步骤 4：选择与模型一致的点
- 步骤 5：重复假设-验证循环

多次重复该过程，每次记录内点数量和质量。

来源：R. Raguram

---

## RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat *hypothesize-and-verify* loop

Source: R. Raguram

30

### RANSAC直线拟合示例


- 步骤 1：随机选择最小子集
- 步骤 2：假设一个模型
- 步骤 3：计算误差函数
- 步骤 4：选择与模型一致的点
- 步骤 5：重复假设-验证循环

如图所示，多轮迭代中有些采样包含离群点，导致拟合结果不佳（虚线所示）。

来源：R. Raguram

## RANSAC for line fitting example

### Uncontaminated sample



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat hypothesize-and-verify loop

Source: R. Raguram

31

## RANSAC直线拟合示例


### 未受污染的子集样本

- 步骤 1：随机选择最小子集
- 步骤 2：假设一个模型
- 步骤 3：计算误差函数
- 步骤 4：选择与模型一致的点
- 步骤 5：重复假设-验证循环

当随机采样恰好选中两个内点时，得到正确的模型假设（实线），大量内点支持该模型。

来源：R. Raguram

## RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat *hypothesize-and-verify* loop

Source: R. Raguram

32

### RANSAC直线拟合示例

- 步骤 1：随机选择最小子集
- 步骤 2：假设一个模型
- 步骤 3：计算误差函数
- 步骤 4：选择与模型一致的点
- 步骤 5：重复假设-验证循环

最终结果：选择拥有最多内点的模型作为最佳拟合，并使用所有内点重新拟合以得到最终直线。

来源：R. Raguram

## RANSAC for line fitting

---

Repeat  $N$  times:

- Draw  $s$  points uniformly at random
- Fit line to these  $s$  points
- Find inliers to this line among the remaining points (i.e., points whose distance from the line is less than  $t$ )
- If there are  $d$  or more inliers, accept the line and refit using all inliers

Source: S. Lazebnik

33

---

## RANSAC直线拟合算法

重复  $N$  次:

- 随机均匀地抽取  $s$  个点
- 对这  $s$  个点拟合一条直线
- 在剩余点中找出该直线的内点 (即到直线的距离小于阈值  $t$  的点)
- 如果内点数量达到  $d$  个或更多, 接受该直线, 并使用所有内点重新拟合

来源: S. Lazebnik

---

## Choosing the parameters

---

- Initial number of points  $s$ 
  - Typically minimum number needed to fit the model
- Distance threshold  $t$ 
  - Choose  $t$  so probability for inlier is  $p$  (e.g. 0.95)
  - Zero-mean Gaussian noise with std. dev.  $\sigma$ :  $t^2 = 3.84\sigma^2$
- Number of samples  $N$ 
  - Choose  $N$  so that, with probability  $p$ , at least one random sample is free from outliers (e.g.  $p=0.99$ ) (outlier ratio:  $e$ )

Source: M. Pollefeys

34

### 参数选择

- 初始采样点数  $s$

通常为拟合模型所需的最少点数

- 距离阈值  $t$

选择  $t$  使得内点概率为  $p$  (如 0.95)

零均值高斯噪声, 标准差为  $\sigma$  时:  $t^2 = 3.84\sigma^2$

- 采样次数  $N$

选择  $N$  使得以概率  $p$ , 至少有一个随机样本不包含离群点 (如  $p = 0.99$ )  
(离群点比例为  $e$ )

来源: M. Pollefeys

学习补充:

- RANSAC 的核心不是一次算出完美模型, 而是反复随机抽最小样本, 找“支持者最多”的模型。
- $s$  是最小样本数,  $d$  是内点阈值,  $N$  是重复次数; 这些参数共同控制鲁棒性和计算量。



## Choosing the parameters

- Initial number of points  $s$ 
  - Typically minimum number needed to fit the model
- Distance threshold  $t$ 
  - Choose  $t$  so probability for inlier is  $p$  (e.g. 0.95)
  - Zero-mean Gaussian noise with std. dev.  $\sigma$ :  $t^2 = 3.84\sigma^2$
- Number of samples  $N$ 
  - Choose  $N$  so that, with probability  $p$ , at least one random sample is free from outliers (e.g.  $p=0.99$ ) (outlier ratio:  $e$ )

$$\left(1 - (1 - e)^s\right)^N = 1 - p$$

$$N = \log(1 - p) / \log(1 - (1 - e)^s)$$

| s | proportion of outliers $e$ |     |     |     |     |     |      |
|---|----------------------------|-----|-----|-----|-----|-----|------|
|   | 5%                         | 10% | 20% | 25% | 30% | 40% | 50%  |
| 2 | 2                          | 3   | 5   | 6   | 7   | 11  | 17   |
| 3 | 3                          | 4   | 7   | 9   | 11  | 19  | 35   |
| 4 | 3                          | 5   | 9   | 13  | 17  | 34  | 72   |
| 5 | 4                          | 6   | 12  | 17  | 26  | 57  | 146  |
| 6 | 4                          | 7   | 16  | 24  | 37  | 97  | 293  |
| 7 | 4                          | 8   | 20  | 33  | 54  | 163 | 588  |
| 8 | 5                          | 9   | 26  | 44  | 78  | 272 | 1177 |

Source: M. Pollefeys

35

### 参数选择（采样次数表）

- 初始采样点数  $s$ : 通常为拟合模型所需的最少点数
- 距离阈值  $t$ : 选择  $t$  使得内点概率为  $p$  (如 0.95), 零均值高斯噪声下  $t^2 = 3.84\sigma^2$
- 采样次数  $N$ : 以概率  $p$  至少有一个随机样本不含离群点

离群点比例与所需采样次数对照表:

$s \setminus e$ : 5% 10% 20% 25% 30% 40% 50%

2 | 2 3 5 6 7 11 17

3 | 3 4 7 9 11 19 35

4 | 3 5 9 13 17 34 72

5 | 4 6 12 17 26 57 146

6 | 4 7 16 24 37 97 293

7 | 4 8 20 33 54 163 588

8 | 5 9 26 44 78 272 1177

公式:  $1 - (1 - e)^s = 1 - p$ ,  $N = \log(1 - p) / \log(1 - (1 - e)^s)$

来源: M. Pollefeys

## Choosing the parameters

---

- Initial number of points  $s$ 
  - Typically minimum number needed to fit the model
- Distance threshold  $t$ 
  - Choose  $t$  so probability for inlier is  $p$  (e.g. 0.95)
  - Zero-mean Gaussian noise with std. dev.  $\sigma$ :  $t^2 = 3.84\sigma^2$
- Number of samples  $N$ 
  - Choose  $N$  so that, with probability  $p$ , at least one random sample is free from outliers (e.g.  $p=0.99$ ) (outlier ratio:  $e$ )
- Consensus set size  $d$ 
  - Should match expected inlier ratio

Source: M. Pollefeys

37

### 参数选择（共识集大小）

- 初始采样点数  $s$

通常为拟合模型所需的最少点数

- 距离阈值  $t$

选择  $t$  使得内点概率为  $p$  (如 0.95)

零均值高斯噪声，标准差为  $\sigma$  时:  $t^2 = 3.84\sigma^2$

- 采样次数  $N$

选择  $N$  使得以概率  $p$ ，至少有一个随机样本不含离群点

- 共识集大小  $d$

应与预期的内点比例相匹配

通常设置为总点数的合理比例

来源: M. Pollefeys

---

## Adaptively determining the number of samples

- Inlier ratio  $e$  is often unknown a priori, so pick worst case, e.g. 50%, and adapt if more inliers are found, e.g. 80% would yield  $e=0.2$
- Adaptive procedure:
  - $N=\infty$ ,  $sample\_count=0$
  - While  $N > sample\_count$ 
    - Choose a sample and count the number of inliers
    - Set  $e = 1 - (\text{number of inliers})/(\text{total number of points})$
    - Recompute  $N$  from  $e$ :

$$N = \log(1-p) / \log(1-(1-e)^s)$$

- Increment the  $sample\_count$  by 1

Source: M. Pollefeys

38

### 自适应确定采样次数

- 内点比例  $e$  通常事先未知，因此选择最坏情况（如 50%），如果发现更多内点则自适应调整（如 80% 内点率意味着  $e = 0.2$ ）

- 自适应过程：

$$N = \infty, sample\_count = 0$$

当  $N > sample\_count$  时：

- 选择一个样本，统计内点数量
- 设  $e = 1 - (\text{内点数}) / (\text{总点数})$
- 根据  $e$  重新计算  $N$ ：

$$N = \log(1-p) / \log(1-(1-e)^s)$$

—  $sample\_count$  增加 1

来源：M. Pollefeys


学习补充：

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
- $s$  是最小样本数， $d$  是内点阈值， $N$  是重复次数；这些参数共同控制鲁棒性和计算量。

## RANSAC pros and cons

---

- Pros
  - Simple and general
  - Applicable to many different problems
  - Often works well in practice
- Cons
  - Lots of parameters to tune
  - Doesn't work well for low inlier ratios (too many iterations, or can fail completely)
  - Can't always get a good initialization of the model based on the minimum number of samples



Source: S. Lazebnik

39

---

### RANSAC的优缺点

优点:

- 简单且通用
- 适用于许多不同的问题
- 在实践中通常效果良好




缺点:

- 需要调节的参数很多
- 对低内点比例情况效果不佳 (可能需要过多迭代, 甚至完全失败)
- 基于最小采样点数的模型初始化不一定总能得到好的初始模型

来源: S. Lazebnik

学习补充:

- RANSAC 的核心不是一次算出完美模型, 而是反复随机抽最小样本, 找“支持者最多”的模型。
- $s$  是最小样本数,  $d$  是内点阈值,  $N$  是重复次数; 这些参数共同控制鲁棒性和计算量。



$$\begin{bmatrix} x_a \\ y_a \end{bmatrix} = \begin{bmatrix} a & b & c \\ d & e & f \end{bmatrix} \begin{bmatrix} x_b \\ y_b \\ 1 \end{bmatrix}$$

