

机器视觉技术


拟合

Fitting — 中文翻译版（含原图）

共 40 页 | 翻译时间：2026年6月

Fitting

(Least squares & RANSAC)



最小二乘法与RANSAC

本章节主要介绍曲线拟合中的两种核心方法：最小二乘法（用于无离群点情况）和RANSAC随机采样一致性算法（用于存在大量离群点的情况）。

左侧图为金属焊盘的再分布凸点图像，展示了需要拟合的几何特征。

Machine Vision Technology							
Semantic information				Metric 3D information			
Pixels	Segments	Images	Videos	Camera		Multi-view Geometry	
Convolutions Edges & Fitting Local features Texture	Segmentation Clustering	Recognition Detection	Motion Tracking	Camera Model	Camera Calibration	Epipolar Geometry	SFM
10	4	4	2	2	2	2	2

机器视觉技术

语义信息 ← → 度量三维信息

像素 → 分割 → 图像 → 视频 → 相机 → 多视图几何

拟合

课程体系概览：从底层像素处理到高层语义理解，拟合是连接特征提取与三维重建的关键环节。

Fitting

- We've learned how to detect edges. Now what?
- We would like to form a higher-level, more compact representation of the features in the image by grouping multiple features according to a simple model



Source: S. Lazebnik

2

拟合

- 我们已经学习了如何检测边缘、角点等特征
- 现在我们希望形成更高级、更紧凑的特征表示
- 通过根据一个简单模型将多个特征分组


简单模型示例：

- 直线
- 圆

来源：S. Lazebnik

Fitting

- Choose a parametric model to represent a set of features



simple model: lines



simple model: circles



complicated model: car

Source: K. Grauman

3

拟合

- 选择一个参数化模型来表示一组特征

简单模型：直线 简单模型：圆

复杂模型：汽车轮廓

来源：K. Grauman

Fitting: Issues

Case study: Line detection



- **Noise** in the measured feature locations
- **Extraneous data**: clutter (outliers), multiple lines
- **Missing data**: occlusions

Source: S. Lazebnik

4

拟合：面临的挑战

案例研究：直线检测

- 测量特征位置中的噪声
- 冗余数据：杂乱背景（离群点）、多条直线
- 缺失数据：遮挡问题

来源：S. Lazebnik

Fitting: Overview

- If we know which points belong to the line, how do we find the “optimal” line parameters?
 - Least squares
- What if there are outliers?
 - Robust fitting, RANSAC
- What if there are many lines?
 - Voting methods: RANSAC, Hough transform
- What if we’re not even sure it’s a line?
 - Model selection

Source: S. Lazebnik

5

拟合：概述

- 如果我们知道哪些点属于这条直线，如何找到「最优」的直线参数？
→ 最小二乘法
- 如果存在离群点怎么办？
→ 鲁棒拟合，RANSAC
- 如果有很多条直线怎么办？
→ 投票方法：RANSAC，霍夫变换
- 如果我们甚至不确定它是不是直线？
→ 模型选择

来源：S. Lazebnik


Least squares line fitting

Data: $(x_1, y_1), \dots, (x_n, y_n)$

Line equation: $y_i = mx_i + b$

Find (m, b) to minimize

$$E = \sum_{i=1}^n (y_i - mx_i - b)^2$$



$$Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \quad X = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \quad B = \begin{bmatrix} m \\ b \end{bmatrix}$$

$$E = \|Y - XB\|^2 = (Y - XB)^T (Y - XB) = Y^T Y - 2(XB)^T Y + (XB)^T (XB)$$

$$\frac{dE}{dB} = 2X^T XB - 2X^T Y = 0$$

$$X^T XB = X^T Y$$

Normal equations: least squares solution to $XB=Y$

Source: S. Lazebnik

6

最小二乘直线拟合

数据: $(x_1, y_1), \dots, (x_n, y_n)$

直线方程: $y_i = mx_i + b$

求 (m, b) 使以下目标函数最小化:

$$E = \sum (y_i - mx_i - b)^2$$

用矩阵形式表示:

$$\begin{aligned} E &= \|Y - XB\|^2 = (Y - XB)^T (Y - XB) \\ &= Y^T Y - 2(XB)^T Y + (XB)^T (XB) \end{aligned}$$

$$dE/dB = 2X^T XB - 2X^T Y = 0$$

正规方程: $X^T XB = X^T Y$

来源: S. Lazebnik

学习补充:

- 直线模型里, 斜率决定倾斜程度, 截距决定与 y 轴的交点。
- 最小二乘要做的是让所有点到直线的误差平方和最小, 因此会得到正规方程。

Problem with “vertical” least squares

- Not rotation-invariant
- Fails completely for vertical lines

Source: S. Lazebnik

7

「垂直」最小二乘法的问题

- 不具备旋转不变性
- 对于垂直直线完全失效


标准最小二乘法最小化的是 y 方向的垂直距离，当直线接近垂直时，误差计算会严重失真。

来源：S. Lazebnik

学习补充：

- 直线模型里，斜率决定倾斜程度，截距决定与 y 轴的交点。
 - 最小二乘要做的是让所有点到直线的误差平方和最小，因此会得到正规方程。
-

Total least squares



Source: S. Lazebnik

8

总体最小二乘法

点 (x_i, y_i) 到直线 $ax + by = d$ 的距离 (其中 $a^2 + b^2 = 1$) :

$$\text{距离} = |ax_i + by_i - d|$$

直线: $ax + by = d$

单位法向量: $N = (a, b)$

总体最小二乘法最小化的是点到直线的垂直 (正交) 距离, 而非仅仅是 y 方向的偏差。

来源: S. Lazebnik

学习补充:


- 当 x/y 两个方向都存在测量误差时, 单纯看竖直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。

Total least squares

Distance between point (x_i, y_i) and line $ax+by=d$ ($a^2+b^2=1$)
 $|ax_i + by_i - d|$

Find (a, b, d) to minimize the sum of squared perpendicular distances

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$



Source: S. Lazebnik

9

总体最小二乘法

点 (x_i, y_i) 到直线 $ax + by = d$ 的距离 (其中 $a^2 + b^2 = 1$) :

$$|ax_i + by_i - d|$$

求 (a, b, d) 使垂直距离的平方和最小化:

单位法向量: $N = (a, b)$

$$E = \sum (ax_i + by_i - d)^2$$

来源: S. Lazebnik

学习补充:

- 当 x/y 两个方向都存在测量误差时, 单纯看竖直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。


Total least squares

Distance between point (x_i, y_i) and line $ax+by=d$ ($a^2+b^2=1$)

$$|ax_i + by_i - d|$$

Find (a, b, d) to minimize the sum of squared perpendicular distances

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$



$$\frac{\partial E}{\partial d} = \sum_{i=1}^n -2(ax_i + by_i - d) = 0$$

$$d = \frac{a}{n} \sum_{i=1}^n x_i + \frac{b}{n} \sum_{i=1}^n y_i = a\bar{x} + b\bar{y}$$

$$E = \sum_{i=1}^n (a(x_i - \bar{x}) + b(y_i - \bar{y}))^2 = \left\| \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \right\|^2 = (UN)^T (UN)$$

$$\frac{dE}{dN} = 2(U^T U)N = 0$$

Solution to $(U^T U)N = 0$, subject to $\|N\|^2 = 1$: eigenvector of $U^T U$ associated with the smallest eigenvalue (least squares solution to *homogeneous linear system* $UN = 0$)

Source: S. Lazebnik

10

总体最小二乘法（推导）

点 (x_i, y_i) 到直线 $ax + by = d$ 的距离 ($a^2 + b^2 = 1$) :

$$|ax_i + by_i - d|$$

求 (a, b, d) 使垂直距离平方和最小化: 单位法向量 $N = (a, b)$

$$E = \sum (ax_i + by_i - d)^2$$

$$\partial E / \partial d = \sum 2(ax_i + by_i - d) = 0$$

$$\Rightarrow d = (a/n) \sum x_i + (b/n) \sum y_i = a\bar{x} + b\bar{y}$$

将数据中心化后:

$$U = [x_1 - \bar{x}, y_1 - \bar{y}; \dots; x_n - \bar{x}, y_n - \bar{y}]$$

$$E = \sum (a(x_i - \bar{x}) + b(y_i - \bar{y}))^2 = \|UN\|^2 = (UN)^T (UN)$$

$$dE/dN = 2(U^T U)N = 0$$

解: 在 $\|N\|^2 = 1$ 约束下, 求 $(U^T U)N = 0$ 的解, 即 $U^T U$ 最小特征值对应的特征向量 (齐次线性系统 $UN = 0$ 的最小二乘解)

来源: S. Lazebnik

学习补充:

- 当 x/y 两个方向都存在测量误差时, 单纯看垂直残差就不够合理, 应该改用正交距离。
- 从概率角度看, 若噪声近似服从高斯分布, 最大似然通常会导向最小二乘。

Total least squares

$$U = \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \quad U^T U = \begin{bmatrix} \sum_{i=1}^n (x_i - \bar{x})^2 & \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) & \sum_{i=1}^n (y_i - \bar{y})^2 \end{bmatrix}$$

second moment matrix

Source: S. Lazebnik

11

总体最小二乘法（二阶矩矩阵）

数据中心化矩阵：

$$U = [x_1 - \bar{x}, y_1 - \bar{y}; x_2 - \bar{x}, y_2 - \bar{y}; \dots; x_n - \bar{x}, y_n - \bar{y}]$$

$$U^T U = [\Sigma(x_i - \bar{x})^2, \Sigma(x_i - \bar{x})(y_i - \bar{y}); \Sigma(x_i - \bar{x})(y_i - \bar{y}), \Sigma(y_i - \bar{y})^2]$$

这就是数据点的 **二阶矩矩阵（散布矩阵）**


来源：S. Lazebnik

学习补充：

- 当 x/y 两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

Total least squares

$$U = \begin{bmatrix} x_1 - \bar{x} & y_1 - \bar{y} \\ \vdots & \vdots \\ x_n - \bar{x} & y_n - \bar{y} \end{bmatrix} \quad U^T U = \begin{bmatrix} \sum_{i=1}^n (x_i - \bar{x})^2 & \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) & \sum_{i=1}^n (y_i - \bar{y})^2 \end{bmatrix}$$



Source: S. Lazebnik

12

总体最小二乘法（几何解释）

数据点的二阶矩矩阵 $U^T U$:

$$U^T U = [\Sigma(x_i - \bar{x})^2, \Sigma(x_i - \bar{x})(y_i - \bar{y}); \Sigma(x_i - \bar{x})(y_i - \bar{y}), \Sigma(y_i - \bar{y})^2]$$

法向量 $N = (a, b)$ 对应 $U^T U$ 的最小特征值所对应的特征向量

几何上，总体最小二乘法寻找使数据点沿法线方向方差最小的直线方向。

图示说明了点 $(\bar{x}, \bar{y})$ 与拟合直线之间的关系。

来源: S. Lazebnik

学习补充:


- 当 x/y 两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

Least squares as likelihood maximization

- **Generative model:** line points are sampled independently and corrupted by Gaussian noise in the direction perpendicular to the line

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} u \\ v \end{pmatrix} + \varepsilon \begin{pmatrix} a \\ b \end{pmatrix}$$

point on the line noise: sampled from zero-mean Gaussian with std. dev. σ normal direction



Source: S. Lazebnik

13

最小二乘法作为似然最大化

- **生成模型:** 直线上的点被独立采样，并在垂直于直线的方向上被高斯噪声干扰

$$(x, y) = (u, v) + \varepsilon \cdot (a, b)$$

其中:

(u, v) — 直线上的一点

(a, b) — 法线方向

ε — 从均值为零、标准差为 σ 的高斯分布中采样的噪声

来源: S. Lazebnik


学习补充:

- 当 x/y 两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

Least squares as likelihood maximization

- **Generative model:** line points are sampled independently and corrupted by Gaussian noise in the direction perpendicular to the line

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} u \\ v \end{pmatrix} + \varepsilon \begin{pmatrix} a \\ b \end{pmatrix}$$



Likelihood of points given line parameters (a, b, d) :

$$P(x_1, y_1, \dots, x_n, y_n | a, b, d) = \prod_{i=1}^n P(x_i, y_i | a, b, d) \propto \prod_{i=1}^n \exp\left(-\frac{(ax_i + by_i - d)^2}{2\sigma^2}\right)$$

$$\text{Log-likelihood: } L(x_1, y_1, \dots, x_n, y_n | a, b, d) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (ax_i + by_i - d)^2$$

Source: S. Lazebnik

14

最小二乘法作为似然最大化（续）

- **生成模型:** 直线上的点被独立采样，在法线方向上被高斯噪声干扰

$$(x, y) = (u, v) + \varepsilon \cdot (a, b)$$

给定直线参数 (a, b, d) ，数据点的似然函数：

$$P(x_1, y_1, \dots, x_n, y_n | a, b, d) = \prod_i P(x_i, y_i | a, b, d) \propto \prod_i \exp(-(ax_i + by_i - d)^2 / (2\sigma^2))$$

对数似然：

$$L(x_1, y_1, \dots, x_n, y_n | a, b, d) = -(1/(2\sigma^2)) \cdot \sum (ax_i + by_i - d)^2$$

最大化对数似然等价于最小化残差平方和，即最小二乘法的概率解释。


来源：S. Lazebnik

学习补充：

- 当 x/y 两个方向都存在测量误差时，单纯看竖直残差就不够合理，应该改用正交距离。
- 从概率角度看，若噪声近似服从高斯分布，最大似然通常会导向最小二乘。

Least squares: Robustness to noise

Least squares fit to the red points:



Source: S.
Lazebnik

15

最小二乘法：对噪声的鲁棒性


对红色点集进行最小二乘拟合：

如图所示，当数据点分布良好（无离群点）时，最小二乘拟合效果很好，能准确地找到最佳拟合直线。

来源：S. Lazebnik

Least squares: Robustness to noise

Least squares fit with an outlier:



Problem: squared error
heavily penalizes outliers

Source: S. Lazebnik

16

最小二乘法：对噪声的鲁棒性

存在一个离群点时的最小二乘拟合：

问题：平方误差对离群点施加了极大的惩罚

如图所示，仅一个离群点就严重扭曲了拟合结果，因为最小二乘法中误差的平方会放大离群点的影响。

来源：S. Lazebnik


Robust estimators

- General approach: find model parameters θ that minimize

$$\sum_i \rho(r_i(x_i, \theta); \sigma)$$

$r_i(x_i, \theta)$ – residual of i th point w.r.t. model parameters θ

ρ – robust function with scale parameter σ



The robust function ρ behaves like squared distance for small values of the residual u but saturates for larger values of u

Source: S. Lazebnik

17

鲁棒估计器

- 一般方法：寻找模型参数 θ 使得：

$$\sum_i \rho(r_i(x_i, \theta); \sigma)$$

其中：

$r_i(x_i, \theta)$ – 第 i 个点相对于模型参数 θ 的残差

ρ – 具有尺度参数 σ 的鲁棒函数

- 鲁棒函数 ρ 的行为：

对于较小的残差值，表现类似于平方距离


对于较大的残差值，函数值趋于饱和（不再增长）

来源：S. Lazebnik

学习补充：

- 鲁棒估计的目的，是让少数离群点不要把整体模型带偏。
- 和普通最小二乘相比，它会弱化大残差点的影响，因此对异常值更稳。

Choosing the scale: Just right



The effect of the outlier is minimized

Source: S. Lazebnik

18

尺度参数的选择：恰到好处


如图所示，当尺度参数选择恰当时：

离群点的影响被最小化

鲁棒函数有效地抑制了离群点对拟合结果的贡献，同时保留了对内点的良好拟合效果。

来源：S. Lazebnik

Choosing the scale: Too small



The error value is almost the same for every point and the fit is very poor

Source: S. Lazebnik

19

尺度参数的选择：过小


如图所示，当尺度参数过小时：

每个点的误差值几乎相同，拟合结果非常差

尺度参数过小会导致鲁棒函数对所有点（包括内点）都饱和，无法区分好点和坏点，拟合失去意义。

来源：S. Lazebnik

Choosing the scale: Too large



Behaves much the same as least squares

Source: S. Lazebnik

20

尺度参数的选择：过大

如图所示，当尺度参数过大时：

行为与最小二乘法几乎相同

尺度参数过大使鲁棒函数的饱和区域过远，大部分点（包括离群点）都落在二次函数区域内，失去了鲁棒性。

来源：S. Lazebnik

Robust estimation: Details

- Robust fitting is a nonlinear optimization problem that must be solved iteratively
- Least squares solution can be used for initialization
- Adaptive choice of scale: approx. 1.5 times median residual (F&P, Sec. 15.5.1)

```

For  $s$  从 1 到  $k$ , 执行循环:
    均匀随机抽取  $r$  个不同的点
    采用最小二乘法拟合该点集得到初始参数  $\theta_s^0$ 
    用  $\theta_s^0$  估计出  $\sigma_s^0$ 
    Until 收敛 (一般指  $|\theta_s^n - \theta_s^{n-1}|$  足够小), 执行以下操作:
        用  $\theta_s^{n-1}, \sigma_s^{n-1}$  通过最小化方法求得  $\theta_s^n$ 
        计算出  $\sigma_s^n$ 
    End
End
  
```

Source: S. Lazebnik

21

鲁棒估计：细节

- 鲁棒拟合是一个非线性优化问题，必须通过迭代求解
- 最小二乘解可用于初始化
- 尺度的自适应选择：约为残差中位数的 1.5 倍 (F&P, 第 15.5.1 节)

算法伪代码：

1. 使用所有点获取初始拟合（如最小二乘）
2. 计算残差并确定尺度参数 σ
3. 使用鲁棒权重进行加权最小二乘拟合
4. 重复步骤 2-3 直到收敛

来源：S. Lazebnik

RANSAC

- Robust fitting can deal with a few outliers – what if we have very many?
- Random sample consensus (RANSAC):
Very general framework for model fitting in the presence of outliers
- Outline
 - Choose a small subset of points uniformly at random
 - Fit a model to that subset
 - Find all remaining points that are “close” to the model and reject the rest as outliers
 - Do this many times and choose the best model

M. A. Fischler, R. C. Bolles. [Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography](#). Comm. of the ACM, Vol 24, pp 381-395, 1981.

Source: S. Lazebnik

22

RANSAC（随机采样一致性）

• 鲁棒拟合可以处理少量离群点 —— 但如果离群点非常多呢？

• **随机采样一致性 (RANSAC) :**

在存在离群点的情况下进行模型拟合的通用框架

• **算法概要:**

- 随机均匀地选择一个小的点子集
- 对该子集拟合一个模型
- 找出所有「接近」模型的剩余点，将其他点作为离群点剔除
- 重复多次，选择最佳模型

文献: M.A. Fischler, R.C. Bolles. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. Comm. of the ACM, Vol 24, pp 381-395, 1981.

来源: S. Lazebnik

学习补充:

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
 - s 是最小样本数， d 是内点阈值， N 是重复次数；这些参数共同控制鲁棒性和计算量。
-

RANSAC for line fitting example



Source: R. Raguram


23

RANSAC直线拟合示例

以下幻灯片展示了RANSAC算法对直线拟合的逐步演示过程。

图中包含一组数据点，其中既有直线上的内点，也有随机分布的离群点。

RANSAC for line fitting example



Least-squares fit

Source: R. Raguram

24


RANSAC直线拟合示例

首先展示最小二乘拟合的结果：

由于存在大量离群点，最小二乘拟合被严重偏离，无法找到正确的直线。

来源：R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points

Source: R. Raguram

25


RANSAC直线拟合示例

步骤 1: 随机选择最小子集

从所有点中随机均匀地选取两个点（拟合直线所需的最少点数）。

来源：R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model

Source: R. Raguram

26

RANSAC直线拟合示例


步骤 1：随机选择最小子集

步骤 2：假设一个模型

使用选中的两个点拟合一条直线作为假设模型。

来源：R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function

Source: R. Raguram

27

RANSAC直线拟合示例

步骤 1: 随机选择最小子集


步骤 2: 假设一个模型

步骤 3: 计算误差函数

计算所有其他点到该假设直线的距离。

来源: R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model

Source: R. Raguram

28


RANSAC直线拟合示例

- 步骤 1: 随机选择最小子集
- 步骤 2: 假设一个模型
- 步骤 3: 计算误差函数
- 步骤 4: 选择与模型一致的点

将与直线距离小于阈值 t 的点标记为内点 (inliers)。

来源: R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat hypothesize-and-verify loop

Source: R. Raguram

29


RANSAC直线拟合示例

- 步骤 1: 随机选择最小子集
- 步骤 2: 假设一个模型
- 步骤 3: 计算误差函数
- 步骤 4: 选择与模型一致的点
- 步骤 5: 重复假设-验证循环

多次重复该过程，每次记录内点数量和质量。

来源: R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat *hypothesize-and-verify* loop

Source: R. Raguram

30

RANSAC直线拟合示例


- 步骤 1: 随机选择最小子集
- 步骤 2: 假设一个模型
- 步骤 3: 计算误差函数
- 步骤 4: 选择与模型一致的点
- 步骤 5: 重复假设-验证循环

如图所示，多轮迭代中有些采样包含离群点，导致拟合结果不佳（虚线所示）。

来源：R. Raguram

RANSAC for line fitting example

Uncontaminated sample



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat hypothesize-and-verify loop

Source: R. Raguram

31

RANSAC直线拟合示例


未受污染的子集样本

- 步骤 1: 随机选择最小子集
- 步骤 2: 假设一个模型
- 步骤 3: 计算误差函数
- 步骤 4: 选择与模型一致的点
- 步骤 5: 重复假设-验证循环

当随机采样恰好选中两个内点时，得到正确的模型假设（实线），大量内点支持该模型。

来源：R. Raguram

RANSAC for line fitting example



1. Randomly select minimal subset of points
2. Hypothesize a model
3. Compute error function
4. Select points consistent with model
5. Repeat *hypothesize-and-verify* loop

Source: R. Raguram

32

RANSAC直线拟合示例

- 步骤 1: 随机选择最小子集
- 步骤 2: 假设一个模型
- 步骤 3: 计算误差函数
- 步骤 4: 选择与模型一致的点
- 步骤 5: 重复假设-验证循环

最终结果: 选择拥有最多内点的模型作为最佳拟合，并使用所有内点重新拟合以得到最终直线。

来源: R. Raguram

RANSAC for line fitting

Repeat N times:

- Draw s points uniformly at random
- Fit line to these s points
- Find inliers to this line among the remaining points (i.e., points whose distance from the line is less than t)
- If there are d or more inliers, accept the line and refit using all inliers

Source: S. Lazebnik

33

RANSAC直线拟合算法

重复 N 次:

- 随机均匀地抽取 s 个点
- 对这 s 个点拟合一条直线
- 在剩余点中找出该直线的内点 (即到直线的距离小于阈值 t 的点)
- 如果内点数量达到 d 个或更多, 接受该直线, 并使用所有内点重新拟合

来源: S. Lazebnik

Choosing the parameters

- Initial number of points s
 - Typically minimum number needed to fit the model
- Distance threshold t
 - Choose t so probability for inlier is p (e.g. 0.95)
 - Zero-mean Gaussian noise with std. dev. σ : $t^2 = 3.84\sigma^2$
- Number of samples N
 - Choose N so that, with probability p , at least one random sample is free from outliers (e.g. $p=0.99$) (outlier ratio: e)

Source: M. Pollefeys

34

参数选择

• 初始采样点数 s

通常为拟合模型所需的最少点数

• 距离阈值 t

选择 t 使得内点概率为 p (如 0.95)

零均值高斯噪声，标准差为 σ 时: $t^2 = 3.84\sigma^2$

• 采样次数 N

选择 N 使得以概率 p ，至少有一个随机样本不包含离群点 (如 $p = 0.99$)
(离群点比例为 e)

来源: M. Pollefeys

学习补充:

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
- s 是最小样本数， d 是内点阈值， N 是重复次数；这些参数共同控制鲁棒性和计算量。

Choosing the parameters

- Initial number of points s
 - Typically minimum number needed to fit the model
- Distance threshold t
 - Choose t so probability for inlier is p (e.g. 0.95)
 - Zero-mean Gaussian noise with std. dev. σ : $t^2=3.84\sigma^2$
- Number of samples N
 - Choose N so that, with probability p , at least one random sample is free from outliers (e.g. $p=0.99$) (outlier ratio: e)

$$\left(1 - (1 - e)^s\right)^N = 1 - p$$

$$N = \log(1 - p) / \log(1 - (1 - e)^s)$$

s	proportion of outliers e						
	5%	10%	20%	25%	30%	40%	50%
2	2	3	5	6	7	11	17
3	3	4	7	9	11	19	35
4	3	5	9	13	17	34	72
5	4	6	12	17	26	57	146
6	4	7	16	24	37	97	293
7	4	8	20	33	54	163	588
8	5	9	26	44	78	272	1177

Source: M. Pollefeys

参数选择（采样次数表）

- 初始采样点数 s ：通常为拟合模型所需的最少点数
- 距离阈值 t ：选择 t 使得内点概率为 p （如 0.95），零均值高斯噪声下 $t^2 = 3.84\sigma^2$
- 采样次数 N ：以概率 p 至少有一个随机样本不含离群点

离群点比例与所需采样次数对照表：

s \ e:	5%	10%	20%	25%	30%	40%	50%
2	2	3	5	6	7	11	17
3	3	4	7	9	11	19	35
4	3	5	9	13	17	34	72
5	4	6	12	17	26	57	146
6	4	7	16	24	37	97	293
7	4	8	20	33	54	163	588
8	5	9	26	44	78	272	1177

公式： $1 - (1 - e)^s = 1 - p$, $N = \log(1 - p) / \log(1 - (1 - e)^s)$

来源：M. Pollefeys

Choosing the parameters

- Initial number of points s
 - Typically minimum number needed to fit the model
- Distance threshold t
 - Choose t so probability for inlier is p (e.g. 0.95)
 - Zero-mean Gaussian noise with std. dev. σ : $t^2 = 3.84\sigma^2$
- Number of samples N
 - Choose N so that, with probability p , at least one random sample is free from outliers (e.g. $p=0.99$) (outlier ratio: e)
- Consensus set size d
 - Should match expected inlier ratio

Source: M. Pollefeys

37

参数选择（共识集大小）

• 初始采样点数 s

通常为拟合模型所需的最少点数

• 距离阈值 t

选择 t 使得内点概率为 p (如 0.95)

零均值高斯噪声，标准差为 σ 时: $t^2 = 3.84\sigma^2$

• 采样次数 N

选择 N 使得以概率 p ，至少有一个随机样本不含离群点

• 共识集大小 d

应与预期的内点比例相匹配

通常设置为总点数的合理比例

来源：M. Pollefeys

Adaptively determining the number of samples

- Inlier ratio e is often unknown a priori, so pick worst case, e.g. 50%, and adapt if more inliers are found, e.g. 80% would yield $e=0.2$
- Adaptive procedure:
 - $N=\infty, sample_count=0$
 - While $N > sample_count$
 - Choose a sample and count the number of inliers
 - Set $e = 1 - (\text{number of inliers})/(\text{total number of points})$
 - Recompute N from e :

$$N = \log(1-p) / \log(1-(1-e)^s)$$

- Increment the *sample_count* by 1

Source: M. Pollefeys

38

自适应确定采样次数

- 内点比例 e 通常事先未知，因此选择最坏情况（如 50%），如果发现更多内点则自适应调整（如 80% 内点率意味着 $e = 0.2$ ）

• 自适应过程:

$N = \infty, sample_count = 0$

当 $N > sample_count$ 时:

— 选择一个样本，统计内点数量

— 设 $e = 1 - (\text{内点数}) / (\text{总点数})$

— 根据 e 重新计算 N :

$N = \log(1-p) / \log(1-(1-e)^s)$

— *sample_count* 增加 1


来源: M. Pollefeys

学习补充:

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
- s 是最小样本数， d 是内点阈值， N 是重复次数；这些参数共同控制鲁棒性和计算量。

RANSAC pros and cons

- Pros
 - Simple and general
 - Applicable to many different problems
 - Often works well in practice
- Cons
 - Lots of parameters to tune
 - Doesn't work well for low inlier ratios (too many iterations, or can fail completely)
 - Can't always get a good initialization of the model based on the minimum number of samples



Source: S. Lazebnik

39

RANSAC的优缺点

优点:

- 简单且通用
- 适用于许多不同的问题
- 在实践中通常效果良好




缺点:

- 需要调节的参数很多
- 对低内点比例情况效果不佳（可能需要过多迭代，甚至完全失败）
- 基于最小采样点数的模型初始化不一定总能得到好的初始模型

来源: S. Lazebnik

学习补充:

- RANSAC 的核心不是一次算出完美模型，而是反复随机抽最小样本，找“支持者最多”的模型。
 - s 是最小样本数， d 是内点阈值， N 是重复次数；这些参数共同控制鲁棒性和计算量。
-



$$\begin{bmatrix} x_a \\ y_a \end{bmatrix} = \begin{bmatrix} a & b & c \\ d & e & f \end{bmatrix} \begin{bmatrix} x_b \\ y_b \\ 1 \end{bmatrix}$$